

Analyse du Corpus SNCF (TextMine)

Rétro-ingénierie des données pour la construction du Benchmark RAG
(Attribution)

Artefacts d'Extraction et de Parsing

Le dataset n'est pas prêt pour l'évaluation. Il présente de sévères problèmes liés à l'extraction aveugle de fichiers PDF et de bases de données hétérogènes :

- > **Caractères de contrôle** Présence de codes `_x0001_` dus à une mauvaise interprétation du formatage PDF.
- > **Tableaux aplatis** Les colonnes de données (ex: vitesses limites) sont concaténées sans espaces, détruisant la sémantique.
- > **Balises HTML** Héritage d'un web-scraping ou d'exports de glossaires internes (balises `<span>`).

```
{"text": "Km fin Restrictions ME120 ME100 MA100 830000 Ligne 1 510,400 516,700 Néa
```

```
106 true, "<span style='font-size:11.0pt'><span>Automoteur de Grande Capacité, constr
```

```
hes suivants : _x0001_ §1 Caractéristiques générales d'exploitation, _x0001_ §2 Di
```

Anomalies de Fenêtrage et de Labellisation

Au-delà du formatage, la logique même de la création des échantillons (samples) pose problème pour un système NLP :

- > **Chunking brutal** : Les contextes sont coupés au milieu de mots ou de phrases.
- > **Faux Positifs** : Le regex de détection ne respecte pas les frontières de mots (ex: trouve "OP" dans "OP14227").
- > **Options "Tout à Faux"** : Des échantillons où absolument toutes les définitions proposées sont étiquetées False, ou des contradictions liées à la casse (majuscules).
- > **Acronym non correspondant au text OU avec variations**

```
nts dont la hauteur des quais est ≥ 760 mm.] [ 1500 V : non étudié ", "acronym": "AGC", "c
```

```
"AGC", "options": {"ARGENTON SUR CREUSE": false, "Autorail Grande Capacité ": true, "<span s
```

```
"acronym": "CMT", "options": {"Contrôle des Mobiles Travaux": false, "Contrat Multi Te  
"Connaissance et maîtrise du territoire": false, "CHAMP-
```



Cohérence du Contexte


De la donnée fragmentée à la modélisation métier

1. Reconstitution Documentaire


L'approche réseau

L'analyse par chevauchement textuel a permis de prouver que les 492 segments ne sont pas indépendants, mais s'agglomèrent autour d'une quarantaine de documents sources.

- **Utilité RAG** : Éviter le découpage aléatoire qui casse le sens technique.
- Reconstituer des "blocs de contexte" sémantiquement cohérents.
- Vérifier si le modèle NLI d'attribution est capable de lier une réponse à un paragraphe fonctionnel réel.
- Ou utilisé ces blocs pour construire des query.



1. Reconstitution Documentaire





Exploitation des Métadonnées


Création du Benchmark via la structure et la géographie

2. Structure & Géographie

Concevoir des requêtes complexes

La documentation SNCF est fortement ancrée géographiquement (Lyon, Paris...) et strictement structurée par articles réglementaires.

- > **Test Multi-Sources** : Poser des questions croisées (ex: Lyon vs Chambéry) pour forcer le RAG à récupérer et fusionner plusieurs documents.
- > **Test Anti-Hallucination** : Utiliser les articles marqués "Réservé" pour générer des questions pièges.
- > Évaluer le rejet d'une affirmation inventée par le LLM.



Le "Stress-Test" Terminologique

Cartographie du bruit et ambiguïté des acronymes

3. Cibler les limites de l'Attribution

Modélisation de l'ambiguïté

Nous avons modélisé la complexité du vocabulaire en croisant la **fréquence**, la **polysémie** et le **bruit induit par les options fausses**.

- **Cibler les "Pires Cas"** : Identifier les acronymes à forte polysémie et fort bruit (ex: AC, EM).
- Pousser le module de recherche (Retriever) à la faute sémantique.
- Vérifier que le module d'Attribution final rejette formellement la réponse si la mauvaise définition est utilisée.

