

Guide d'Annotation : Attribution de Phrases à des pages dans de documents

Atelier EvalLLM @ CORIA TALN2026

Juin 2026

1 Objectif

Ce document définit les protocoles pour l'annotation de la relation entre une **phrase généré** et la page d'un **document source**. L'objectif est de valider si l'information contenue dans la phrase est explicitement ou implicitement supportée par la page du document fourni.

2 Description de la tâche : Attribution Granulaire des Sources en RAG (RAG-Attribution)

L'objectif est d'évaluer la capacité des modèles à identifier précisément quels documents sources soutiennent chaque affirmation (phrase) d'une réponse générée. Contrairement à l'attribution au niveau du document global, cette tâche exige une fidélité au niveau de la phrase. Description de la tâche

Les participants doivent effectuer une classification multi-label pour chaque phrase d'une réponse fournie. Pour chaque phrase, il s'agit de déterminer, parmi un ensemble de documents candidats, lesquels contiennent l'information nécessaire pour justifier ladite phrase.

2.1 Format des Données

2.1.1 Entrée (Input)

Les participants reçoivent un fichier JSON contenant une liste d'objets. Chaque objet contient :

- `questio_id` : Un identifiant unique.
- `question` : La requête de l'utilisateur.
- `documents` : Un dictionnaire d'extraits de référence `doc_id` : texte.
- `answer_sentences` : Une liste de phrases constituant la réponse complète.

2.1.2 Sortie (Output)

Les participants doivent soumettre un dictionnaire où :

- La clé est le `question_id`.

- La valeur est une liste de listes. Chaque sous-liste correspond à une phrase de la réponse et contient les doc_id attribués à cette phrase.

2.2 Métrique d'évaluation

La métrique d'évaluation recommandée est F1-Score Macro-Averaged (Multi-label). Chaque étiquette (chaque document possible) sera traité de manière égale, comme une phrase peut être justifiée par plusieurs documents (redondance) ou aucun (hallucination), le F1-score équilibre la Précision (ne pas citer de documents non pertinents) et le Rappel (citer tous les documents qui soutiennent effectivement l'affirmation).

2.3 Exemples Illustratifs

2.3.1 Exemple d'Entrée (Input)

Listing 1 – Input

```
{
  "question_id": "task_001",
  "question": "Quels sont les effets secondaires du médicament X et son m",
  "documents": {
    "doc_A": "Le médicament X doit être pris par voie orale, de préférence",
    "doc_B": "Les effets secondaires fréquents du médicament X incluent d",
    "doc_C": "Il est recommandé de boire beaucoup d'eau après l'ingestion",
  },
  "answer_sentences": [
    "Le médicament X s'administre par la bouche.",
    "Il peut provoquer des céphalées.",
    "Ce traitement est efficace contre la grippe."
  ]
}
```

2.3.2 Exemple de Sortie attendue (Output)

Listing 2 – Output

```
{
  "task_001": [
    ["doc_A"],
    ["doc_B"],
    []
  ]
}
```

2.3.3 Analyse de l'exemple :

- Phrase 1 : "par la bouche" correspond à "voie orale" dans doc_A.
- Phrase 2 : "céphalées" est un synonyme de "maux de tête" présent dans doc_B.
- Phrase 3 : L'information sur la grippe n'est présente dans aucun document (cas d'hallucination ou d'apport de connaissances externes), la liste est donc vide.

3 Les Règles d'Exclusion

Exclusion de titres/soustitres : Toute phrase identifiée comme étant un **titre** ou un **sous-titre** au sein d'une phrase est considérée comme un élément de structure et non comme un contenu informatif vérifiable.

- Ces segments doivent être marqués comme **Non Attribuables**.
- Justification : Un titre annonce un sujet mais ne constitue pas en soi une preuve factuelle suffisante pour valider une affirmation complexe.

Exclusion de éléments non-textuelles : Toute phrase composé des éléments non-textuelles (markup ou autre) est considérée comme un élément de structure.

- Ces segments doivent être marqués comme **Non Attribuables**.

4 Les Règles d'Inclusion

Si une phrase est segmentée erronément, cad elle est fractionné en plusieurs phrases, tous les morceaux sont attribuables (attention, il faudra discuter sur l'évaluation, peut-être qu'une valeur de continuité ou pas de l'attribution est intéressant) ?

5 Catégories d'Annotation

Les annotations doivent suivre la nomenclature suivante :

1. **Attribution (Score : id de la page) :** La phrase est une copie exacte, une paraphrase fidèle ou une conséquence logique directe d'une partie du corps de la page. Si une partie seulement de l'information est présente, ou la phrase mélange des faits sourcés et des éléments externes, il faut qu'au moins le 40% de la phrase soit attribuable à la page. Étant le 40% un seuil difficile à gérer, il est souhaitable de discuter les cas limites entre annotateurs.
2. **Absence d'Attribution (Score : O) :** Le document n'est pas similaire à la phrase, ne supporte pas la phrase, la contredit, ou la phrase porte moins de 30% d'information en relation à la page.

6 Matrice de Décision

Cas de figure	Décision	Note
Paraphrase sémantique	Attribution	Utilisation de synonymes.
Inférence logique directe	Attribution	Ex : A implique B.
Information ajoutée (date, lieu)	Attribution	Si le reste est vrai.
Titre/Sous-titre ou éléments non textuelles	Absence	Priorité absolue.
Contradiction factuelle	Absence	Information opposée.

7 Exemples Illustratifs

Identifiant de la page (nom_du_fichier__numéro_de_page) :
ObsDrones - Bulletin de veille n°8 - mars-avril 2025.pdf__10

Texte Source :

“Serco a lancé en février l’USV USX-1 Defiant du programme NOMARS de la DARPA. L’USX-1, long de 54,9 m avec un déplacement de 240 t, vise à démontrer des « avantages significatifs », notamment la fiabilité en mer, l’efficacité hydrodynamique et des caractéristiques furtives. Le programme a été lancé en 2020 et Serco a été sélectionné en 2022. Le NOMARS vise une fiabilité de 90 % en mer pendant un an et une capacité de ravitaillement autonome. Les USV Mariner et Ranger ont démontré la capacité de ravitaillement de SERCO lors d’un test en septembre dernier. Le Defiant va subir deux mois d’essais en mer avant « une démonstration très large du navire et de ses capacités ». ***Analyse*** : Avec l’USX-1 Defiant, la DARPA marque une étape importante et devrait pousser l’USN à faire des choix et progresser rapidement dans le domaine. La suite logique, une fois les démonstrations validées, est le lancement par l’USN d’un programme. ***Analyse*** : L’approche est intéressante et montre qu’Anduril cherche en permanence à s’adapter voire à devancer le marché. Le développement d’armes anti-sous-marines spécifiques pour les UAV/USV/UUV ne fait aucun doute. Anduril se positionne en tête mais sera rejoint rapidement par d’autres acteurs du secteur. 10”

- **Phrase** : “1. ***Sur le plan opérationnel*** :”
→ **Label** : O (Raison : Titre de section).
- **Phrase** : “ — — — ”
→ **Label** : O (Raison : éléments non textuelles).
- **Phrase** : “Les systèmes autonomes comme l’USX-1 Defiant ***transforment la logistique militaire*** en permettant des ***missions prolongées et autonomes*** (ravitaillement, reconnaissance).”
→ **Label** : ObsDrones - Bulletin de veille n°8 - mars-avril 2025.pdf__10
(Raison : La phrase est fidèle du corps de la page en plus de 40% de son contenu).
- **Phrase** : « Le PIB a augmenté de 3% en 2025 et 2026. »
→ **Label** : O (Raison : Le texte ne porte pas sur le sujet).

8 exemples du corpus session 1/52

session 1/52.

s2 : Le Bayraktar TB3, capable de décoller depuis le Ski Jump du TCG Anadolu (Contexte 1), assurerait des missions de reconnaissance ou de frappe, en coordination avec d’autres drones comme l’Akinci pour un partage de données en temps réel.

doc : Baykar annonce avoir réalisé, le 1er juin, le 1er sur Ski Jump du TB3. Le test a eu lieu au centre de formation et d’essai au vol de Baykar à Keşan, Edirne. La piste a été construite pour répondre aux spécifications des conditions du pont du TCG Anadolu. Elle comprend une rampe avec une pente de 12°. Au cours du test, le TB3 a effectué avec succès quatre décollages. Il s’agit du 46ème vol d’essais du TB3. Baykar confirme son intention de commencer à tester le Bayraktar TB3 sur le TCG Anadolu en 2024

analyse : il est clair qu’il s’agit du Bayraktar TB3 mais la confirmation s’il sera capable de décoller du TCG Anadolu sera fait en 2024, le teste fait est sur une centre de forma-

tion avec des conditions du pont du TCG Anadolu, mais la confirmation sera obtenue uniquement lors du test en 2024.

Conclusion : on peut attribuer partiellement une source, mais si des informations sont faussement attribués à la source, l'attribution ne doit pas avoir lieu. NON ATTRIBUABLE.

9 exemples du corpus session 2/52

session 2/52.

s5 : L'USV "Avdiyivka", armé et réutilisable (Contexte 2), compléterait cette couche aérienne par des missions de patrouille, attaque, ou soutien logistique, avec une autonomie accrue.

doc : Le Service de Sécurité Ukrainien reçoit une nouvelle génération d'USV, l'« Avdiyivka » Source : Militarnyi Analyse : À ce stade, les caractéristiques et les performances de cet USV ne sont pas diffusées. Cependant, il apparaît clairement que les services ukrainiens continuent de développer des USV. Le 1er USV de nouvelle génération « Avdiyivka » a été produit pour le Service de sécurité de l'Ukraine. Le SSU a annoncé que cet USV est doté de ses propres armes, qu'il peut utiliser plus d'une fois. Le SSU ne divulgue pas le type d'armes installées sur l'« Avdiyivka ». Selon, le SSU, ce nouveau USV ne ciblerait pas seulement les installations maritimes.

analyse : il est clair qu'il s'agit de l'Avdiyivka et qu'on peut dire qu'il est armé et réutilisable. Après, on ne peut pas conclure que ce n'est pas vrai que "compléterait cette couche aérienne par des missions de patrouille, attaque, ou soutien logistique, avec une autonomie accrue".

Conclusion : on peut attribuer partiellement une source et sans possibilité de vérifier le reste de l'information, l'attribution doit avoir lieu. ATTRIBUABLE.

10 exemples du corpus session 17/52

s1 : Le Sea Baby (USV) se distingue par son environnement maritime et ses capacités offensives ou multirôles (lance-roquettes, mitrailleuse), avec une autonomie adaptée aux missions navales, notamment en mer Noire.

doc (phrases pertinentes) : L'Ukraine dévoile un USV Sea Baby armé de roquettes et d'une mitrailleuse...Le Service de sécurité ukrainien (SBU) a dévoilé des variantes améliorées de l'USV Sea Baby, (qui existe depuis 2023) : l'une dotée d'un lance-roquettes multiple de 122 mm de type Grad et l'autre d'une station d'armement à distance dotée d'une mitrailleuse de 12,7 mm. Le Sea Baby évolue passant d'un UAV/OWA à un UAV multirôles.

doc (attention des mentions de la mer, mais pas pertinentes) : La marine ukrainienne a intercepté et détruit un USV kamikaze en mer Noire. L'USV a été détecté dans les eaux territoriales de l'Ukraine, à proximité des routes de navigation civiles, grâce aux actions coordonnées de la marine et du renseignement de défense de l'Ukraine. Il n'est pas précisé ce qui a exactement détruit l'USV. Il est probable qu'il s'agisse d'un tir d'arme légère ou de l'utilisation d'un drone kamikaze ukrainien. Le type d'USV russe n'est pas divulgué.

analyse : la parti multi-rôles est relevante, mais mineure dans la phrase. Le sens de la phrase me fait penser que la notion maritime est majeure et elle ne peut pas être attribué aux parties relevantes à Sea Baby du document.

conclusion : NON ATTRIBUABLE.

11 exemples du corpus session 20/52

s5 : Cependant, sa masse réduite (11,3 kg) et son absence de senseurs maritimes le rendent inadapté aux opérations navales prolongées.

doc (phrases pertinentes) : Le Hellhound S3 est une LM imprimée en 3D, propulsée par un turboréacteur, conçue pour des capacités de frappe de précision à longue portée. Elle est annoncée avec une vitesse de pointe de plus de 610 km/h. Le Hellhound S3 aurait une masse de 11,3 kg. Sa conception modulaire permet d’alterner les charges utiles entre ogives cinétiques, CU GE ou capteurs ISR en moins de cinq minutes et sans outils. Cummings Aerospace prévoit d’autres essais en vol au cours des prochains mois pour faire progresser le système jusqu’à TRL-7. La société a également candidaté pour le programme

analyse : malgré la mention du poids, il n’y a pas de mention sur l’absence de senseurs maritimes et la relation entre ces dernières et les opération navales prolongées. Le modèle qui a généré la réponse fait donc appel à sa mémoire paramétrique.

conclusion : NON ATTRIBUABLE.

12 exemples du corpus session 20/52

s3 : Ce mini-drone comble partiellement le vide en renseignement tactique pour l’armée de terre, mais son utilité reste limitée sans le SDT Patroller, dont la livraison est reportée.

doc (phrases pertinentes) : À la fin de l’année 2021, l’armée de terre aura reçu près de la moitié de sa capacité de minidrones de renseignement Spy ranger, destinés à remplacer ses vieux DRAC et la Marine commence à recevoir ses drones aériens Aliaca, destinés à équiper ses bâtiments de second rang. Les difficultés se concentrent en revanche sur le segment des drones tactiques. En raison d’un crash lors d’un vol d’essai en décembre 2019, la livraison des premiers SDT Patroller, initialement prévue en 2018, est désormais espérée pour 2022. Or, comme on le sait, l’armée de terre a dû, en raison de problèmes de sécurité, renoncer à utiliser ses SDTI hors d’âge et se trouve donc totalement privée de capacités sur ce segment.

analyse : temporalement parlant la fenêtre de livraison du Spy ranger (fin de l’année 2021) et du SDT Patroller (espérée pour 2022) n’est pas si lointaine. De plus la relation entre ces deux n’est pas si évidente pour conclure une utilité limitée Spy ranger du sans le SDT Patroller.

conclusion : NON ATTRIBUABLE.

13 exemples du corpus session 26/52

s8 : Déployer des drones marins

s9 : chargés de protéger des infrastructures sous-marines.

doc (phrases pertinentes) : Les drones sont amenés à jouer un rôle décisif en termes de cartographie des fonds marins, de surveillance des infrastructures sous-marines, de conduite d’opérations ou de démonstrations in situ.

analyse : phrase anormalement segmenté que est une paraphrase du texte. Individuellement, elles ne sont pas attribuables car incomplètes, mais ensemble on peut les attribuer.

conclusion : ATTRIBUABLE.

14 exemples du corpus session 26/52

s3 : 45 % des frappes françaises en 2020).

doc (phrases pertinentes) : armés et délivrent, depuis le début de l'année 2020, environ 45 % des frappes. » (1) Pour la seule année 2020, les drones Reaper ont effectué 58 % des frappes aériennes réalisées, contre 29 % pour la chasse et 13 % pour les hélicoptères d'attaques de l'aviation légère de l'armée de terre.

analyse : sûrement une hallucination générée par la proximité entre valeurs. Notez que la valeur de 45% est très proche de l'information (année 2020). La vraie valeur est 58% pour l'exemple.

conclusion : NON ATTRIBUABLE.

15 exemples du corpus Session 47/52

s0 Pour assurer une défense navale cohérente, une stratégie intégrée pourrait s'articuler autour de trois axes clés, exploitant les systèmes testés lors de REPMUS 24 :

s1 Détection et surveillance persistante :

s2 Utiliser la barrière anti-sous-marine de REPMUS 24 (37 UAV, 20 USV, 36 UUV) pour identifier et surveiller les menaces sous-marines dans des zones spécifiques, en créant un réseau de détection étendu.

s3 Frappe rapide et mobile :

s4 Déployer le missile Kuzgun-KY depuis des USV Marlin pour cibler les menaces identifiées, exploitant sa vitesse supersonique et sa portée de 50 km pour une neutralisation immédiate sans exposer de navires habités.

doc (phrases pertinentes) : Source : Turdef TURQUIE 02/10/2024 Le missile anti-navire Tubitak Kuzgun-KY a été tiré d'un lanceur fixe, 8 cellules, installé sur un USV Marlin. Le Kuzgun-KY est annoncé avec une portée de 50 km, une vitesse « supersonique » et une CU de 10 kg. Analyse : Il s'agit d'un essai majeur bien que le résultat n'ait pas été annoncé. Ce type de missile devrait aussi équiper des UAV turcs. 11 Bulletin de veille d'actualité n°5 / Septembre-Octobre 2024 REPMUS 24 : le plus grand exercice international d'USV /UUV/UAV démarre au Portugal Source : Army Recognition Analyse : L'exercice est majeur pour l'OTAN mais également pour de nombreux industriels qui voient de nombreux clients potentiels tester et/ou voir des démonstrations de leurs produits en condition réelle. Selon les informations publiées par le ministère portugais de la Défense, l'exercice REPMUS 24 (Robotic Experimentation and Prototyping using Maritime Unmanned Systems) a officiellement commencé à Troia et à Sesimbra, l'événement se déroulant jusqu'au 27 septembre. L'édition de cette année, la 14ème, rassemble plus de 2 000 participants de 30 pays. REPMUS est un événement naval annuel organisé par la marine portugaise, en collaboration avec l'OTAN et de multiples partenaires internationaux. Cet exercice se concentre sur la mise à l'essai et l'avancement des technologies de systèmes maritimes, UAV, UUV, USV dans des scénarios complexes du monde réel. L'objectif principal de REPMUS est de favoriser l'interopérabilité entre les marines de l'OTAN et des alliés, tout en développant et en perfectionnant l'utilisation de systèmes sans équipage dans des opérations telles que la lutte anti-sous-marine, la lutte contre les mines, les missions ISR. L'exercice offre aux pays et aux partenaires de l'OTAN une plate-forme pour expérimenter des concepts innovants, améliorant ainsi l'intégration des technologies sans pilote avec les moyens habités traditionnels. Dans le cadre de l'exercice, le projet de barrière anti-sous-marine de l'OTAN a mobilisé 37 UAV, 20 USV, 36

UUV, ainsi que 15 navires de guerre et 10 navires de recherche, afin de créer une barrière de détection et de surveillance sous-marine pour identifier des menaces dans des zones spécifiques (identifier, surveiller et éventuellement neutraliser les sous-marins ennemis qui représentent une menace pour les bases navales, les voies de navigation ou d'autres éléments d'infrastructure sous-marine critiques). Parmi les autres concepts testés, la marine portugaise aurait expérimenté le concept de base maritime sans équipage, appelée « île », entièrement autonome et autosuffisante, utilisée pour soutenir les opérations de systèmes maritimes sans équipage. OTAN 11/09/2024

analyse : malgré que l'information de s4 vient directement du document, tant la question, comme la réponse, portent sur l'exercice REPMUS 24. L'information en s4 est hors le contexte de l'information de l'exercice REPMUS donc non attribuable au à l'exercice REPMUS. Cependant, la réponse est au conditionnelle et la question demande une combinaison de ces informations.

conclusion : ATTRIBUABLE pour s4. (mais pas à REPMUS, cependant ce n'est pas une information indiqué dans la configuration actuelle).

16 Contradictions

Certains contradictions on été identifiés lors de l'annotation :

Un titre a été attribué si le titre fait partie importante de la suite de l'information. Par exemple, dans la Session 30/52 :

- s4 Le GJ-11 se distingue par :
- s5 Une endurance de 4 à 6 heures, suffisante pour de nombreuses missions maritimes.

car s4 est une précédent important de s5. Dans de cas dans lesquels s4 état un titre générique (par exemple "Synthèse") l'attribution portera uniquement sur s5.

17 Limitations

- Une limitation claire de la méthodologie d'annotation est que lors qu'une phrase peut faire allusion à deux document comme sources, pas independement sinon par la combinaison est analyses de deux documents comme un ensemble, la méthodologie ne permet pas de faire l'attribution.
- La qualité de segmentation de phrases peut générer des ambiguïtés comme dans les exemples 13.
- Il aurait été judicieux d'avoir établi un "niveau" d'attribution car certains phrases sont partiellement attribuables. Le problème pourrait être contourné avec une granularité plus fine (i.e. sous-phrases) mais le problème de la qualité de la segmentation se pose. Le compromis peut-être d'établir de niveaux d'attribution pour permettre garder de phrases cohérentes mais indiquer que l'attribution n'est que partiel dans certains cas.
- les documents qui portent sur plusieurs événements (ou informations) peuvent être un risque pour l'attribution, car la réponse peut porter sur un seul événements et faire appel à des phrases de tout le document. Cette limitation est généré par les multiples informations qui peu porter un document et peu être atténue si les documents portent sur une "unique" information.